

YOLOv8 交通标志检测模型训练分析报告



高性能交通标志检测模型训练过程详解

训练概览

训练时间: 2025年10月31日 - 2025年11月1日

训练参数	数值
模型类型	YOLOv8s
训练轮数	30
批次大小	16
图像大小	640×640
优化器	SGD
学习率策略	余弦退火
数据集	new_GTSRB

最终性能指标

精确率

99.77%

召回率

99.91%

mAP50


99.50%

mAP50-95

97.33%

训练指标可视化


1. 损失值变化趋势



损失值分析:

- **训练损失**: 从第一个epoch的总和约4.14，逐渐下降到最后一个epoch的约1.56，下降了约62%。
- **box_loss**: 从0.78降至0.34，说明模型定位能力显著提升。
- **cls_loss**: 从2.06大幅下降到0.15，表明分类准确率大幅提高。
- **dfl_loss**: 从1.31降至1.07，边界框回归损失稳定下降。
- **验证损失**: 保持与训练损失相似的下行趋势，但数值更低，表明模型泛化能力良好。

2. 性能指标变化




性能指标分析:

- **精确率与召回率:** 精确率从80.76%快速上升到99.77%，召回率从84.28%提升到99.91%。
- **mAP50:** 从89.10%稳步提升到99.50%，最终达到几乎完美的检测效果。
- **mAP50-95:** 从78.91%提升到97.33%，表明在不同IoU阈值下都有出色表现。
- **学习率:** 采用余弦退火策略，从较高的初始值逐渐降低，有助于模型收敛和避免过拟合。
- **训练时间:** 每个epoch的训练时间相对稳定，表明训练过程高效。

3. 指标相关性分析


训练指标相关性热力图



相关性分析洞察:

- **正相关**: 验证集的box_loss、cls_loss和dfi_loss之间存在强正相关，表明这些损失组件协同变化。
- **负相关**: 损失值与性能指标（精确率、召回率、mAP）呈现明显的负相关，损失下降伴随着性能提升。
- **训练与验证一致性**: 训练损失和验证损失之间存在较强相关性，说明模型训练稳定，没有明显过拟合。

4. 训练前后性能对比



性能提升对比:

- **精确率**: 从80.76%提升到99.77%，增长了19.01个百分点。
- **召回率**: 从84.28%提升到99.91%，增长了15.63个百分点。
- **mAP50**: 从89.10%提升到99.50%，增长了10.40个百分点。
- **mAP50-95**: 从78.91%提升到97.33%，增长了18.42个百分点。
- **全方位提升**: 雷达图清晰展示了模型在所有关键性能指标上的显著进步。

🔍 训练过程深度分析

阶段划分

1. 快速提升阶段 (Epoch 1-10)

- 所有性能指标快速上升，损失值急剧下降
- mAP50从89.10%提升到约97%
- 模型快速学习基本特征和模式

2. 稳定提升阶段 (Epoch 11-20)

- 性能指标持续上升但速度放缓
- 损失值继续稳步下降
- 模型开始学习细粒度特征

3. 精细调优阶段 (Epoch 21-30)

- 性能指标小幅提升，趋近于极限
- 学习率进一步降低
- 模型参数精细化调整，泛化能力增强

关键发现

- **模型收敛性**：训练在30个epoch内成功收敛，最终mAP50达到99.50%，表明模型对数据集有极佳的适应能力。
- **过拟合控制**：验证损失与训练损失保持同步下降，没有出现明显的过拟合现象，余弦退火学习率策略效果良好。
- **分类与定位平衡**：box_loss和cls_loss的同步下降表明模型在定位和分类任务上都取得了均衡的改进。
- **计算效率**：训练过程高效稳定，每个epoch的训练时间相对一致，表明训练配置合理。

 结论与建议

总体结论

训练的YOLOv8s模型在交通标志检测任务上表现出色，最终达到了接近完美的检测性能。这表明：

- **模型选择恰当**：YOLOv8s在精度和速度之间取得了良好的平衡。
- **训练策略有效**：SGD优化器结合余弦退火学习率表现优秀。
- **数据集质量高**：new_GTSRB数据集提供了足够的训练信息，支持模型达到高准确率。

优化建议

1. 模型轻量化：

- 考虑使用YOLOv8n进行部署，在保持高精度的同时提高推理速度。

2. 数据增强：

- 可以尝试更多的数据增强技术，如随机缩放、旋转、亮度变化等，进一步提高模型的鲁棒性。

3. 超参数调优：

- 尝试不同的学习率初始值和衰减策略，可能会进一步提升性能。
- 探索其他优化器如AdamW的效果。

4. 模型集成：

- 考虑集成多个不同训练参数的模型，可能会进一步提高检测性能。

5. 部署优化：

- 利用模型量化和剪枝技术，优化模型在边缘设备上的部署效果。

后续工作方向

- **实际场景测试**: 在真实道路场景中测试模型性能
- **多尺度目标优化**: 针对不同大小的交通标志进行专项优化
- **实时性能评估**: 测量模型在实际应用环境中的推理速度
- **异常检测能力**: 评估模型对未见过的交通标志类型的鲁棒性

 报告生成时间: 2025年11月1日

 模型保存路径: `runs/detect/new_gtsrb_yolov8_v2/weights/best.pt`